PROPOSAL TUGAS BESAR PENGGANTI UAS (MILESTONE M1) · SUB-TOPIK T3-A

Perbandingan Acak Warna vs Penyamaan Warna (Stain Normalization) pada Segmentasi Sel Darah Putih saat Pindah Alat Mikroskop

Kelompok 6 · Deep Learning for Image – Computer Vision Lanjutan (Kelas A) · S1 Sistem Informasi UTM
Dosen: Dr. Wahyudi Setiawan, S.Kom., M.Kom. · GitHub: github.com/attaramadhani/UAS-DL-Kelompok6-T3A-WBC-DomainShift

1. Masalah yang Kami Teliti, Pertanyaan Riset, dan Dugaan Awal

Masalah Klinis: Model AI pemisah bagian sel darah putih (inti sel/nukleus dan cairan sel/sitoplasma) biasanya akurat di satu laboratorium, tetapi nilainya sering turun drastis saat dipakai pada foto dari mikroskop dan cairan pewarna berbeda (domain shift). Di topik T3-A, kami menguji masalah ini secara dua arah antara foto mikroskop biasa berlatar kekuningan (D1) dan foto mesin CellaVision berlatar keunguan (D2).

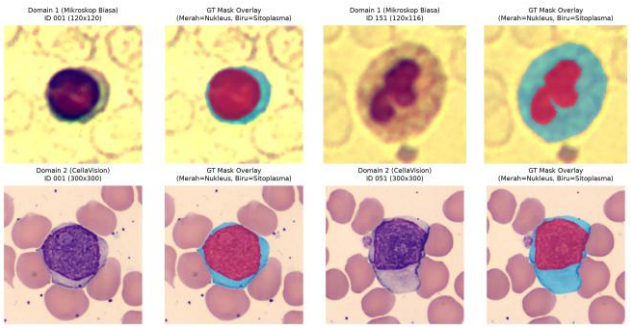
Pertanyaan Riset: Saat kami melatih model U-Net dan DeepLabV3+ memakai foto mikroskop biasa (D1) lalu mengujinya pada foto CellaVision (D2)—dan sebaliknya dari D2 ke D1—seberapa besar teknik penyamaan warna (Macenko dan Reinhard) mampu menjaga akurasi (Dice, IoU per kelas, mIoU, dan ketepatan tepi HD95) dibandingkan cara mengacak warna saat latihan (ColorJitter) atau tanpa penyesuaian warna sama sekali?

Dugaan Awal (Hipotesis): (1) Kami menduga penyamaan warna Macenko (yang menyesuaikan warna foto uji agar mirip dengan 1 contoh foto latih) akan membuat akurasi saat pindah alat turun paling sedikit dan lebih stabil daripada sekadar mengacak warna (ColorJitter) maupun model polos; (2) Kami juga memperkirakan DeepLabV3+ (dengan filter pandang melebar/ASPP) akan lebih tahan terhadap perbedaan ukuran gambar dan batas cairan sel dibandingkan U-Net standar.

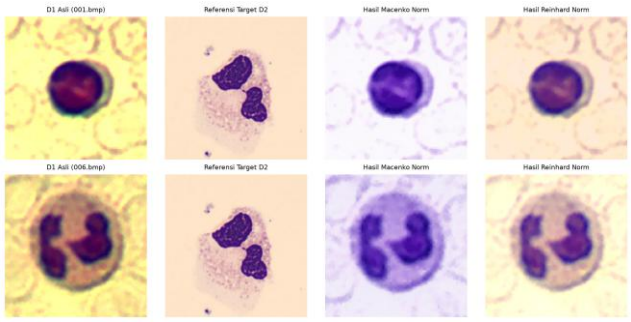
2. Dataset yang Dipakai, Temuan Pengecekan Data, dan Pembagian Data (Seed = 42)

Data Sumber: Kami memakai dataset resmi Zheng et al. (Micron 2018) di Mendeley Data (DOI: 10.17632/w7cvnmn4c5.1). Dataset 1 (D1) berisi 300 foto mikroskop Motic/N800-D bernuansa kekuningan (rata-rata RGB [223.8, 198.8, 165.7]; porsi area rata-rata: latar 68.73%, sitoplasma 18.81%, nukleus 12.46%). Dataset 2 (D2) berisi 100 foto CellaVision 300×300 bernuansa keunguan (rata-rata RGB [210.5, 171.0, 174.7]; latar 77.24%, sitoplasma 12.65%, nukleus 10.10%).

Temuan Cek Data: Saat mengecek seluruh file asli dengan skrip src/audit_eda.py, kami menemukan 3 hal penting yang langsung kami bereskan: (1) Ukuran foto D1 tidak seragam (ada 30 ukuran dari 88×88 hingga 120×120; hanya 224 foto yang pas 120×120), sehingga semuanya diseragamkan ke 256×256; (2) Lima masker D2 (034, 035, 047, 050, 076.png) punya sisa piksel kotor bernilai 2–50 selain [0, 128, 255], jadi langsung kami bersihkan ke kelas 0/1/2; (3) Uji kesamaan file (SHA-256) & kemiripan gambar (dHash) menemukan 1 pasang foto kembar persis (D1/112 & D1/139) dan 1 pasang sangat mirip (D1/166 & D1/171). Pasangan kembar ini kami satukan ke data latih pada splits/zheng_d1_split.csv (210 latih / 45 validasi / 45 uji) dan splits/zheng_d2_split.csv (70 / 15 / 15) agar kebocoran data = 0. Data uji hanya dibuka sekali di akhir.



Gambar 1. Contoh foto asli & label pakar (D1 kuning vs D2 ungu).



Gambar 2. Hasil uji penyamaan warna Macenko & Reinhard (D1 disamakan ke D2).

3. Rencana Percobaan (Dijalankan di Google Colab Pro / T4 · Total 25 Kali Latih)

Bagian Uji	Model yang Dipakai	Pengaturan yang Diuji	Jml	Penanggung Jawab & Tujuan
Uji Utama (D1→D2)	U-Net & DeepLabV3+ (ResNet-34)	Loss CE+Dice, 256×256, 3 seed acak (42,123,999)	6	Tim · Ukur nilai rata-rata ± variasi
Uji Utama (D2→D1)	U-Net & DeepLabV3+ (ResNet-34)	Loss CE+Dice, 256×256, 3 seed acak (42,123,999)	6	Tim · Tes arah balik (D2 ke D1)
Ablasi 1 (Warna)	U-Net (ResNet-34, D1→D2)	Polos vs Acak Warna vs Macenko vs Reinhard	4	Attala · Inti topik T3-A
Ablasi 2 (Loss)	U-Net (ResNet-34, D1→D2)	Cross-Entropy vs Dice Loss vs Gabungan (CE+Dice)	3	Nafaul · Atasi beda luas sel
Ablasi 3 (Ukuran/Aug)	DeepLabV3+ (ResNet-34, D1→D2)	128×128+flip/putar vs 256×256 tanpa vs pakai flip	3	M. Rafly · Efek ukuran & rotasi
Ablasi 4 (Backbone)	DeepLabV3+ (D1→D2)	ResNet-34 Penuh vs MobileNetV2 vs Bekukan Encoder	3	Naufal · Banding akurasi & cepatnya
Perkiraan Waktu	Bobot ImageNet, batch 16, 40 epoch	Sekitar 1.5–2.5 menit tiap kali latih di Colab	25×	Total ±45–65 menit GPU (aman)

4. Pembagian Tugas Kelompok 6 (Masing-Masing Pegang 1 Percobaan / Ablasi)

Nama Anggota	NIM	Tugas Utama di Tim	Percobaan Pribadi (1 Pengaturan Diubah)
Attala Alif Ramadhani Tri Hida	230441100144	Ketua tim, Model 1 (U-Net), gabung kode & laporan	Banding warna: Polos vs ColorJitter vs Macenko vs Reinhard
Nafaul Hernanda Romadlona	240441100125	Siapkan & cek data, jaga agar tidak bocor, log	Banding fungsi loss: Cross-Entropy vs Dice vs CE+Dice
M. Rafly Kurniawan	240441100086	Model 2 (DeepLabV3+), jalankan 3 seed & cek GPU	Banding ukuran foto (128 vs 256) & putar/balik foto
Naufal Husain	240441100038	Hitung skor per gambar, kumpulan salah & Grad-CAM	Banding tulang punggung model: ResNet-34 vs MobileNetV2

5. Cara Mengukur Hasil, Analisis Kesalahan, dan Kerapian Kode

Nilai Akurasi: Kami menghitung skor Dice dan IoU untuk setiap gambar lalu mengambil rata-rata dan simpangan bakunya. Penilaian bagian Sitoplasma dan Nukleus dipisah agar terlihat jelas bagian mana yang sering meleset, ditambah mIoU dan jarak ketepatan tepi (HD95 dalam satuan piksel).

Cek Salah & Fokus AI: Kami mengumpulkan minimal 8 foto hasil prediksi terburuk lalu mengelompokkan penyebabnya (misal warna terlalu jauh berubah, cairan sel melebar ke sel darah merah, atau batas inti sel bergeser). Selain itu, kami membuat peta panas Grad-CAM untuk 4 tebakan benar dan 4 tebakan salah agar terlihat apakah AI benar-benar melihat inti sel atau malah terganggu oleh latar gambar.

Kecepatan & Kerapian: Kami mencatat jumlah parameter model dan kecepatan menebak 1 gambar (diulang 50 gambar setelah 10 kali pemanasan) pada GPU yang sama. Semua skrip kode, daftar pembagian data (splits/), notebook Colab, serta hasil audit awal sudah tersimpan rapi di GitHub tanpa mengunggah file dataset mentah.