PROPOSAL TUGAS BESAR PENGGANTI UAS (MILESTONE M1) · SUB-TOPIK T3-A

Augmentasi Warna vs Stain Normalization pada Segmentasi Semantik Nukleus–Sitoplasma Sel Darah Putih Lintas Domain

Kelompok 6 · Deep Learning for Image – Computer Vision Lanjutan (Kelas A) · S1 Sistem Informasi UTM
Dosen: Dr. Wahyudi Setiawan, S.Kom., M.Kom. · GitHub: github.com/attaramadhani/UAS-DL-Kelompok6-T3A-WBC-DomainShift

1. Latar Belakang, Pertanyaan Riset, dan Hipotesis Awal

Masalah Klinis: Model segmentasi semantik sel darah putih (WBC) untuk memisahkan nukleus dan sitoplasma biasanya bekerja bagus di satu laboratorium, tetapi performanya sering turun drastis ketika diuji pada citra dari mikroskop dan pewarnaan yang berbeda (domain shift). Di sub-topik T3-A, kami menguji masalah ini secara dua arah antara citra mikroskop konvensional berlatar kekuningan (D1) dan citra scanner CellaVision berlatar keunguan (D2).

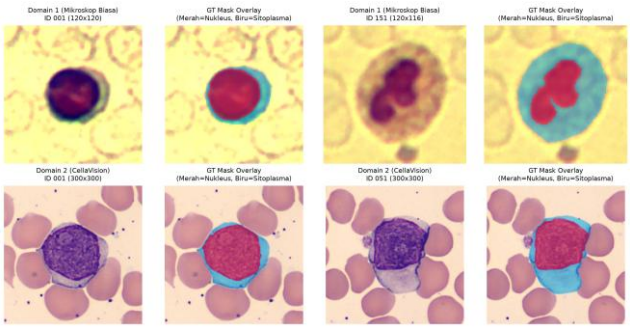
Pertanyaan Riset: Saat kami melatih model U-Net (Encoder–Decoder) dan DeepLabV3+ (ASPP) menggunakan dataset mikroskop konvensional (D1) lalu mengujinya pada dataset CellaVision (D2)—serta arah sebaliknya (D2 ke D1)—sejauh mana teknik stain normalization (Macenko dan Reinhard) lebih efektif menjaga metrik Dice, IoU per kelas, mIoU, dan HD95 dibandingkan color augmentation (ColorJitter) maupun baseline tanpa adaptasi?

Hipotesis Awal: (1) Kami menduga stain normalization (Macenko) berbasis referensi satu citra set train target akan menekan penurunan performa cross-domain lebih baik dan lebih stabil daripada ColorJitter maupun baseline tanpa adaptasi; (2) Kami juga memperkirakan DeepLabV3+ dengan modul ASPP lebih tahan terhadap perubahan skala resolusi dan kontras sitoplasma antar-domain dibandingkan U-Net standar.

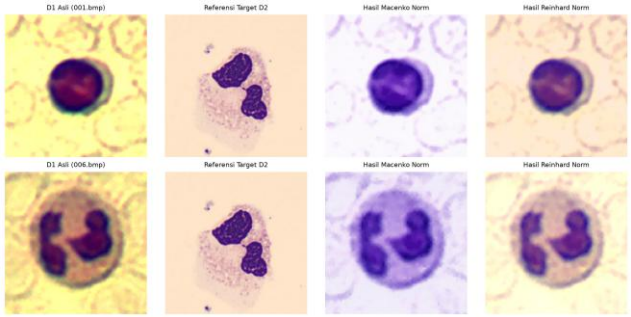
2. Dataset Resmi, Temuan Audit Data, dan Rencana Split (Seed = 42)

Profil Dataset: Kami memakai dataset resmi Zheng et al. (Micron, 2018) dari Mendeley Data (DOI: 10.17632/w7cvnmn4c5.1). Dataset 1 (D1) berisi 300 citra mikroskop optik Motic/N800-D berlatar kekuningan (rerata RGB [223.8, 198.8, 165.7]; proporsi piksel rata-rata: background 68.73%, sitoplasma 18.81%, nukleus 12.46%). Dataset 2 (D2) berisi 100 citra CellaVision 300×300 berlatar keunguan (rerata RGB [210.5, 171.0, 174.7]; background 77.24%, sitoplasma 12.65%, nukleus 10.10%).

Hasil Audit & Anti-Leakage: Saat memeriksa file asli memakai skrip src/audit_eda.py, kami menemukan 3 kondisi yang langsung kami tangani sebelum training: (1) Citra D1 memiliki 30 resolusi berbeda (88×88 hingga 120×120; 224 citra berukuran 120×120), sehingga seluruh citra kami resize ke 256×256; (2) Lima ground truth mask D2 (034, 035, 047, 050, 076.png) mengandung noise piksel 2–50 di luar [0, 128, 255], sehingga langsung kami kuantisasi menjadi label kelas {0, 1, 2}; (3) Uji SHA-256 & perceptual dHash menemukan 1 duplikat eksak (D1/112 & D1/139, MAE=0.0) dan 1 near-duplicate (D1/166 & D1/171, dHash=2 bit). Pasangan kembar ini kami satukan ke split train pada splits/zheng_d1_split.csv (210 train / 45 val / 45 test) dan splits/zheng_d2_split.csv (70 / 15 / 15) sehingga data leakage = 0. Set test hanya dipakai satu kali di akhir.



Gambar 1. Sampel citra asli & GT mask overlay (D1 kekuningan vs D2 keunguan).



Gambar 2. Preview Macenko & Reinhard Stain Normalization (D1 → referensi train D2).

3. Rencana Eksperimen (Google Colab Pro / T4 · Total 25 Run Terkontrol)

Kelompok Run	Model & Paradigma	Kondisi / Variabel Uji	Jml	Pemilik & Tujuan
Uji Utama (D1→D2)	U-Net & DeepLabV3+ (ResNet-34)	Loss CE+Dice, 256×256, geom aug, 3 seed (42,123,999)	6	Tim · Rerata ± SD in/cross-domain
Uji Utama (D2→D1)	U-Net & DeepLabV3+ (ResNet-34)	Loss CE+Dice, 256×256, geom aug, 3 seed (42,123,999)	6	Tim · Evaluasi balik D2 ke D1
Ablasi 1 (Warna)	U-Net (ResNet-34, D1→D2)	Baseline vs ColorJitter vs Macenko vs Reinhard	4	Attala · Inti sub-topik T3-A
Ablasi 2 (Loss)	U-Net (ResNet-34, D1→D2)	Cross-Entropy vs Dice Loss vs Combo (CE+Dice)	3	Nafaul · Tangani class imbalance
Ablasi 3 (Resolusi/Aug)	DeepLabV3+ (ResNet-34, D1→D2)	128×128+geom vs 256×256+none vs 256×256+geom	3	M. Rafly · Input size & geom aug
Ablasi 4 (Encoder/FT)	DeepLabV3+ (D1→D2)	ResNet-34 Full vs MobileNetV2 Full vs ResNet-34 Frozen	3	Naufal · Trade-off akurasi & latency
Estimasi Resource	Pretrained ImageNet, batch 16, 40 epoch	Sekitar 1.5–2.5 menit per run di Colab Pro/T4	25 run	Total ±45–65 menit GPU (realistis)

4. Pembagian Peran Kelompok 6 (Masing-Masing 1 Studi Ablasi)

Nama Anggota	NIM	Peran Utama di Tim	Studi Ablasi Pribadi (1-Faktor)
Attala Alif Ramadhani Tri Hida	230441100144	Ketua tim, Model U-Net, integrasi pipeline & laporan	Adaptasi warna: Baseline vs ColorJitter vs Macenko vs Reinhard
Nafaul Hernanda Romadlona	240441100125	Audit data/EDA, deduplikasi split & experiment logging	Loss function: Cross-Entropy vs Dice Loss vs CE+Dice
M. Rafly Kurniawan	240441100086	Model DeepLabV3+, eksekusi multi-seed & benchmark GPU	Input resolution (128 vs 256) & geometric augmentation
Naufal Husain	240441100038	Metrik per citra, error gallery & Grad-CAM	Encoder & fine-tuning: ResNet-34 vs MobileNetV2 & freeze vs full

5. Metrik Evaluasi, Analisis Kesalahan (XAI), Efisiensi, dan Reproduksibilitas

Evaluasi Per Citra: Kami menghitung Dice dan IoU per citra lalu melaporkannya sebagai rerata ± simpangan baku secara terpisah untuk kelas Sitoplasma dan Nukleus, ditambah mIoU serta HD95 (satuan piksel) untuk menilai ketepatan batas tepi segmentasi.

Error Analysis & Grad-CAM: Kami menyusun error gallery berisi minimal 8 prediksi terburuk lengkap dengan kategori kesalahan dan frekuensinya (mis. domain shift berat, over-segmentation sitoplasma ke RBC, under-segmentation tepi pucat, atau kesalahan batas nukleus–sitoplasma), serta visualisasi Grad-CAM dari layer akhir encoder untuk minimal 4 prediksi benar dan 4 prediksi salah.

Efisiensi & Reproduksibilitas: Kami mengukur jumlah parameter (juta) dan rata-rata latency inferensi (batch=1, 50 citra setelah 10× warm-up) pada satu GPU yang konsisten. Seluruh skrip modular (src/), file split tetap (splits/), notebook Colab, serta hasil audit awal sudah tersimpan rapi di GitHub tanpa mengunggah berkas dataset mentah.